



Documento de Validación y Pruebas

Modelo de Readmisión Hospitalaria — Ejecución local, API y Docker

Materia:	Gestión de Proyectos de Inteligencia Artificial
Actividad:	Fase II — Solución técnica desplegable
Alumno(a):	JUAN ANDRES GUTIERREZ MARTINEZ
Matrícula:	07144441
Docente:	LUIS ARIEL VAZQUEZ PEÑA
Fecha de entrega:	12 / 07 / 2026

Declaración de Uso de Inteligencia Artificial

El alumno debe indicar de manera honesta si utilizó herramientas de Inteligencia Artificial (IA) para el desarrollo de esta actividad. Se completa la siguiente tabla:

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	☐ No	
Claude (Anthropic)	☒ Sí	Diseño de los casos de prueba, ejecución de la simulación y del contenedor, redacción y estructuración del documento de validación.
Gemini (Google)	☐ No	
Copilot (Microsoft)	☐ No	
Otra (especifica):	☐ No	

Desarrollo de Contenido

1. Introducción

La simulación de ejecución local es una etapa preventiva indispensable que permite verificar la fiabilidad de un modelo de inteligencia artificial antes de su despliegue en entornos productivos. Este documento presenta la validación y las pruebas realizadas sobre el modelo de predicción de readmisión hospitalaria a 30 días, con el fin de confirmar que se carga correctamente, genera predicciones coherentes y responde conforme a lo esperado, tanto en ejecución local como dentro del contenedor Docker.

La validación se apoya en una lista de verificación (checklist) que abarca la carga del modelo, las pruebas funcionales con casos comunes, la evaluación de casos extremos, la validación básica con probabilidades, las pruebas de la API y las pruebas automatizadas.

Checklist de validación local

- Contar con el modelo previamente entrenado (model.pkl).
- Desarrollar un script de prueba con casos comunes y esperados.
- Ejecutar la simulación e interpretar los resultados.
- Evaluar casos extremos (límite).
- Realizar una validación básica con probabilidades (nivel de confianza).
- Comprobar la integración mediante la API (endpoints) y el contenedor Docker.

2. Desarrollo

2.1 Descripción del modelo y variables

El modelo es un clasificador binario Random Forest (200 árboles, profundidad máxima 8) que estima la probabilidad de readmisión de un paciente. Se aplica un umbral operativo de 0.30: si la probabilidad de readmisión es mayor o igual a 0.30, el caso se clasifica como alto riesgo (clase 1). Este umbral se ajustó para maximizar el recall y evitar omitir pacientes de alto riesgo.

El modelo recibe 12 variables clínicas de entrada:

Variable	Descripción	Rango
edad	Edad del paciente (años)	18 – 95
num_diagnosticos	Número de diagnósticos	0 – 16
num_medicamentos	Número de medicamentos	0 – 25
dias_estancia	Días de estancia hospitalaria	0 – 30
visitas_urgencias_previas	Visitas previas a urgencias	0 – 12
nivel_glucosa	Nivel de glucosa (mg/dL)	70 – 400
presion_arterial	Presión arterial sistólica (mmHg)	90 – 220

Variable	Descripción	Rango
indice_masa_corporal	Índice de masa corporal	18 – 55
num_procedimientos	Número de procedimientos	0 – 12
hospitalizaciones_previas	Hospitalizaciones previas	0 – 10
indice_adherencia	Adherencia al tratamiento (1 = perfecta)	0 – 1
num_comorbilidades	Número de comorbilidades	0 – 12

2.2 Metodología de pruebas

La validación se ejecutó en cuatro frentes complementarios: (1) simulación local con el script `simular.py`; (2) pruebas de integración de la API con `cliente_api.py` mediante solicitudes HTTP reales; (3) pruebas funcionales automatizadas con `pytest` (`tests/test_api.py`); y (4) verificación del contenedor Docker en ejecución. Todos los datos son sintéticos y con fines educativos.

2.3 Pruebas funcionales (casos comunes)

Se evaluaron casos representativos de bajo, medio y alto riesgo. Las predicciones resultaron coherentes con los factores clínicos de riesgo.

Caso	Perfil	Prob. readmisión	Predicción
Bajo riesgo	Joven, buena adherencia, sin comorbilidades	0.04	0 — No readmitido
Riesgo medio	Crónico moderado, adherencia parcial	0.48	1 — Alto riesgo
Alto riesgo	Adulto mayor, múltiples factores de riesgo	0.89	1 — Alto riesgo

2.4 Casos extremos evaluados (límite)

Se probaron valores en los extremos de los rangos para validar un comportamiento realista ante escenarios límite.

Caso extremo	Prob. readmisión	Predicción	Comportamiento
Mínimos absolutos (paciente sano ideal)	0.10	0 — No readmitido	Correcto (bajo riesgo)
Máximos absolutos (deterioro extremo)	0.76	1 — Alto riesgo	Correcto (alto riesgo)
Caso frontera cercano al umbral	0.11	0 — No readmitido	Coherente con el umbral 0.30

2.5 Validación básica con probabilidades

Además de la clasificación, el modelo cuantifica el nivel de riesgo mediante `predict_proba`. Esto permite establecer una regla de alerta adicional: una probabilidad de readmisión superior a 0.70 marca al paciente para revisión prioritaria, aun cuando la clasificación ya sea de alto riesgo.

Caso	P(no readmisión)	P(readmisión)	Interpretación
Bajo riesgo	0.96	0.04	Alta confianza en clasificación legítima

Caso	P(no readmisión)	P(readmisión)	Interpretación
Alto riesgo	0.11	0.89	Alta confianza en alto riesgo — alerta prioritaria

2.6 Pruebas de integración de la API (endpoints)

Con el servicio en ejecución, el cliente `cliente_api.py` consumió los endpoints por HTTP, verificando los códigos de estado y las respuestas.

Endpoint	Método	Entrada	HTTP	Resultado
/health	GET	—	200	status: ok, modelo_cargado: true
/metadata	GET	—	200	12 variables, umbral 0.30, AUC 0.792
/predict	POST	Caso bajo riesgo	200	No readmitido (0.036)
/predict	POST	Caso alto riesgo	200	Alto riesgo (0.892)
/predict	POST	Solo 3 variables	400	Error de validación controlado

2.7 Pruebas automatizadas (pytest)

La suite de pruebas funcionales verificó la salud del servicio, la estructura de la respuesta, la coherencia (alto riesgo $\geq$ bajo riesgo) y la validación de entradas inválidas. Resultado: 6 pruebas superadas de 6 (6 passed).

```
tests/test_api.py::test_health PASSED
tests/test_api.py::test_metadata PASSED
tests/test_api.py::test_predict_estructura PASSED
tests/test_api.py::test_predict_alto_riesgo_mayor_bajo PASSED
tests/test_api.py::test_predict_validacion_num_vars PASSED
tests/test_api.py::test_predict_validacion_no_numerico PASSED
===== 6 passed in 3.35s =====
```

2.8 Métricas del modelo y tablero de resultados

El desempeño del modelo se evaluó sobre el conjunto de prueba (20 % de los datos) con el umbral operativo 0.30. Las métricas obtenidas son:

Métrica	Valor	Interpretación
Recall (sensibilidad)	0.72	Detecta el 72 % de los pacientes realmente readmitidos
F1-score	0.58	Balance entre precisión y recall en clase minoritaria
AUC-ROC	0.79	Buena capacidad de discriminación (0.5 = azar)

La siguiente figura resume la matriz de confusión, la curva ROC y la predicción por caso de prueba:

Tablero de validacion - API de readmision hospitalaria (Fase II)




Figura 1. Tablero de validación del modelo de readmisión hospitalaria.

2.9 Verificación del contenedor Docker (evidencia real)

La imagen se construyó con Docker 29.6.1 (docker build) y el contenedor se ejecutó con el puerto 5000 publicado (docker run). La imagen se generó correctamente y el contenedor quedó operativo con estado de salud healthy, sirviendo el frontend y respondiendo a los endpoints:

Verificación	Resultado obtenido
docker --version	Docker version 29.6.1
Imagen construida	readmision-api:1.0.0 — 699 MB (build exitoso)
Contenedor (docker ps)	Up (healthy) — 0.0.0.0:5000 -> 5000/tcp
Healthcheck del contenedor	healthy
GET /health (por el contenedor)	200 — status: ok, modelo_cargado: true
POST /predict (alto riesgo)	200 — Readmitido (alto riesgo), prob. 0.8922
POST /predict (entrada inválida)	400 — error de validación controlado
Servidor de aplicación	gunicorn 23.0.0, 2 workers en 0.0.0.0:5000

El frontend, servido por el contenedor Docker en <http://localhost:5000>, se muestra a continuación:

Referencias Bibliográficas

- Banerjee, I. (2024). Dockerizing Your Machine Learning Model: A Step-by-Step Guide. <https://medium.com/@indradumnabanerjee/dockerizing-your-machine-learning-model-a-step-by-step-guide-12e92f8c960e>
- Scikit-learn. (2024). RandomForestClassifier — scikit-learn documentation. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>
- SG Systems. (2025). ISO/IEC 23053 — Marco del ciclo de vida del sistema de IA. <https://sgsystemsglobal.com/es/glosario/>
- Susnjara, S., y Smalley, I. (s.f.). ¿Qué son los contenedores? IBM. <https://www.ibm.com/mx-es/think/topics/containers>